

Identifikace lidí podle písma

Samuel Kiszka, David Klajbl, Matuš Pestun

Vedoucí: Ing. Jan Kohút

8. května 2026

Abstrakt

V této práci představujeme systém pro identifikaci autora rukopisu z fotografie ručně psaného textu v otevřené množině identit autorů. Systém extrahuje lokální patche z většího obrázku rukopisu, které jsou zpracovány sdílenou konvoluční sítí a převedeny na sadu embeddingů. Tyto embeddingy tvoří vstup do transformer encoderu, který modeluje jejich vzájemné vztahy, a výsledná reprezentace celého vstupního vzorku je agregována pomocí globálního poolingů. Identifikace autora probíhá na základě dotazování nad galerií referenčních vzorků. Experimentálně porovnáváme různé metody extrakce patchů (náhodná; dle pravidelné mřížky; dle klíčových bodů metody SIFT) a zkoumáme vliv počtu extrahovaných patchů a jejich velikosti na identifikační výkon systému.

1 Úvod

Cílem projektu bylo vytvořit systém pro identifikaci autora rukopisu z fotografie ručně psaného textu. Konkrétně byla řešena úloha identifikace v otevřené množině identit, ve které musel systém kromě správného určení známých autorů také rozpoznat a odmítnout vzorky pocházející od neznámých autorů. Požadavkem bylo, aby systém dokázal generalizovat na dosud neviděné autory, kteří nebyli součástí trénovacích dat.

Úloha je typicky řešena pomocí učení reprezentací s využitím obrazového enkodéru, který mapuje vstupní snímky rukopisu (řádky či celé stránky) do embeddingového prostoru. Model lze trénovat metodami metrického učení tak, aby reprezentace rukopisů téhož autora byly v embeddingovém prostoru blízké, zatímco reprezentace různých autorů byly vzájemně vzdálené [1].

Pro účely identifikace lze následně využít galerii referenčních embeddingů jednotlivých autorů. Dotazované vzorky jsou porovnávány se vzorky uloženými v galerii na základě metriky podobnosti v embeddingovém prostoru, což umožňuje určení identity autora dotazovaného vzorku nebo případné odmítnutí vzorku neznámého autora [3].

Existuje mnoho odlišných přístupů, jak realizovat obrazový enkodér pro identifikaci autora rukopisu. V současnosti se často používají přístupy založené na extrakci menších patchů z obrazu zachycujících lokální rysy písma. Z těchto patchů jsou následně získány deskriptory, které jsou agregovány do výsledné globální reprezentace [8, 3]. Výhodou je, že tyto metody nejsou závislé na velikosti vstupního textu a jsou robustnější vůči různému obsahu textu (napsaná slova nejsou klíčová). Nevýhodou je, že se ztrácí informace o globální struktuře textu a sekvenční informace obsažené v textu, jako

například tahové přechody mezi písmeny, sklon písma a vzdálenosti mezi jednotlivými znaky a slovy.

Abdelillah Semma et al. (2021) [8] kombinuje metody FAST a Harris corner k detekci klíčových bodů obrazu. Patche jsou extrahovány z okolí klíčových bodů a následně jsou enkódovány sdílenou CNN. Výstupní lokální embeddingy jsou agregovány metodou VLAD do globální reprezentace dokumentu. Identifikace autora je následně provedena metodou k-nearest neighbors (kNN) nad galerií referenčních embeddingů dokumentů autorů.

Michael Koepf et al. (2022) [3] využívá detekci klíčových bodů metodou SIFT. Z okolí těchto bodů jsou extrahovány obrazové patche, které jsou následně binarizovány metodou Otsu. Každý patch je zpracován lehkým Vision Transformerem (ViT-Lite), který vytváří jeho latentní reprezentaci. Reprezentace všech patchů v rámci dokumentu jsou následně agregovány (mean pooling) do globální reprezentace dokumentu. Pro identifikaci autora je opět použita metoda kNN nad galerií referenčních embeddingů.

2 Navržené řešení


Schéma navrženého systému pro identifikaci autora rukopisu je znázorněno na obrázku 1. Vstupem systému je černobílý obrázek jednoho řádku krátkého úryvku ručně psaného textu. Modul *Patch Extractor* z něj podle zvolené strategie vybírá fixní počet obrazových patchů. Sada těchto patchů je následně vstupem *Patch Set Encoderu*, který z nich vytváří embedding reprezentující autora.

Výsledný embedding je dále použit jako dotaz do galerie, která obsahuje embeddingové reprezentace referenčních vzorků jednotlivých autorů. Identifikace je realizována porovnáním embeddingu dotazovaného vzorku s embeddingy v galerii pomocí kosinové podobnosti. Výstupem je skóre podobnosti vůči jednotlivým vzorkům galerie.

Pro získání jednoho skóre pro každého autora, které vyjadřuje míru příslušnosti dotazovaného vzorku k danému autorovi, je pět nejvyšších skóre vzorků daného autora průměrováno. Oproti průměrování přes všechna skóre je tento přístup odolnější vůči šumu a outlierům a oproti max pooling je rozhodování stabilnější.

Pokud skóre nejpravděpodobnějšího autora překročí stanovený práh, je vzorek přiřazen danému autorovi. V opačném případě je odmítnut a označen jako nepříslušející žádnému autorovi z galerie.

Následující sekce se věnují popisu modulů *Patch Extractor* a *Patch Set Encoder* a také prezentují baseline řešení.



Obrázek 1: Schéma navrženého systému pro identifikaci autora rukopisu.

Modul Patch Extractor

Modul *Patch Extractor* využívá jeden z následujících tří způsobů patchování:

- náhodný výběr patchů,
- pravidelný výběr patchů dle mřížky,
- výběr patchů dle klíčových pozic získaných metodou SIFT [4].

Ve všech případech je vybírán konstantní počet patchů se shodnými rozměry. Pozice patchů v rámci obrázku je ignorována u náhodného výběru a výběru dle SIFT při vstupu do *Patch Set Encoderu*.

Modul Patch Set Encoder

Obecné schéma *Patch Set Encoderu* je znázorněno na obrázku 2. Jednotlivé patche jsou zpracovány sdílenou konvoluční sítí *PatchCNN*. Architektura se skládá ze čtyř konvolučních bloků s postupnou prostorovou redukcí pomocí max-poolingu a následným globálním average poolingem, který převádí každý patch na jednorozměrný 256-dimenzionální embedding. Cílem je extrakce lokální informace obsažené v patchi.

Sada embeddingů patchů je vstupem do Transformer encoderu, který se skládá ze dvou vrstev, které využívají osm attention hlav a feed-forward síť se skrytou dimenzí 1024. Pokud byly patche extrahovány pravidelně dle mřížky, je k embeddingům přidán poziční encoding. Cílem použití transformeru je obohacení původně nezávislých reprezentací patchů o kontextovou informaci o jejich vzájemných vztazích.

Výstupní embeddingy transformer encoderu jsou agregovány pomocí multi-head attention poolingem se čtyřmi hlavami

do globální reprezentace. Tento embedding je projektován na požadovanou dimenzionalitu a následně L2-normalizován.

Baseline řešení


Navrhované řešení bylo porovnáno s jednoduchým baseline modelem, jehož backbone tvoří architektura ResNet18 [2]. Na vstupu je jeden výřez z černobílého obrázku řádku textu o velikosti 48×512 pixelů. Kratší řádky jsou doplněny nulami (padding) na požadované rozměry.

Kernel první konvoluční vrstvy ResNet18 byl upraven na menší velikost (3×3) se stride 1 a paddingem 1, což umožňuje jemnější zachycení detailů v datech. První max-pooling vrstva byla odstraněna, aby nedocházelo k předčasné ztrátě detailů.

Poslední poolingová vrstva a plně propojená vrstva byly odstraněny a nahrazeny Generalized-Mean (GeM) poolingem [6], který v realizovaných experimentech dosáhl lepších výsledků než attention pooling i mean 2D pooling. Výstup je následně lineární projekcí transformován na požadovanou velikost embeddingu (128) a poté L2 normalizován.

3 Datová sada

Datová sada pro trénink a evaluaci modelu byla vytvořena sloučením tří dílčích datových sad: interní datové sady poskytnuté vedoucím práce, IAM Handwriting Database [5] a datasetu ze soutěže AnyScript Challenge [7]. Datové sady obsahují vzorky ve formě obrázků řádků ručně psaného textu od různých autorů. Počty autorů a vzorků jednotlivých datových sad a statistiky počtu vzorků na jednoho autora jsou uvedeny v tabulce 1.



Obrázek 2: Architektura enkodéru pro získání embeddingu autora ze sady extrahovaných patchů.

	Interní	IAM	AnyScript
# autorů	5 092	657	998
# vzorků	406,636	13,353	9,031,707
min	1	2	1
median	42	11	2,004
avg	79	20	9,049
max	6,961	582	607,962

Tabulka 1: Statistiky datových sad.

Datové sady byly sloučeny a následně filtrovány tak, aby výsledná sada obsahovala pouze autory s alespoň 50 vzorky na autora a vzorky o minimální šířce 300 pixelů. Výška obrázků se pohybuje od 40 do 48 pixelů. Minimální počet vzorků byl zvolen s ohledem na využití metrického učení, zatímco minimální šířka měla zajistit dostatečné množství informací o rukopisu.

Tabulky 2 a 3 uvádějí počty autorů a vzorků výsledné datové sady rozdělené na trénovací, validační a testovací část, spolu se statistikami počtu vzorků na autora v trénovací množině.

Část	# autorů	# vzorků
trénovací	2,091 (79.7%)	5,491,345 (94.8%)
validační	257 (9.8%)	151,008 (2.6%)
testovací	274 (10.5%)	150,975 (2.6%)

Tabulka 2: Statistiky splitů.

Sada	min	mediat	avg	max
trénovací	50	100	2,626	258,870

Tabulka 3: Statistiky počtu vzorků na autora v trénovací sadě.

Předzpracování dat

Vzhledem k vysoké výpočetní náročnosti detekce klíčových bodů metodou SIFT byly klíčové body všech vzorků datové sady předem extrahovány. Pro každý obrázek byla extrahována množina 100 klíčových bodů. Jelikož metoda SIFT nezaručuje nalezení požadovaného počtu klíčových bodů, byly chybějící body doplněny pomocí náhodného vzorkování. Experimentálně se však ukázalo, že počet takto doplněných bodů

je statisticky zanedbatelný, zejména pro nižší počty bodů, jak ukazuje Tabulka 4.

Počet patchů	10	20	30	50
Průměr SIFT	9.89	19.46	28.57	45.27
Směr. odch.	0.78	2.44	4.82	10.94
Podíl SIFT	98.9 %	97.3 %	95.2 %	90.5 %

Tabulka 4: Statistiky počtu SIFT klíčových bodů pro 13 531 vzorků od 162 různých autorů.

4 Experimenty

Cílem experimentů bylo porovnat tři strategie extrakce patchů: náhodné vzorkování (RANDOM), pravidelnou mřížku (GRID) a výběr klíčových bodů metodou SIFT, a pro každou z nich najít optimální hodnoty klíčových hyperparametrů.

V rámci experimentů byly systematicky variovány následující parametry:

- **Počet patchů N :** Více patchů přináší encoderu více informací, avšak zvyšuje výpočetní nároky a omezuje velikost batche při tréninku. Pro RANDOM a SIFT byly testovány hodnoty $N \in \{15, 50, 80\}$. U GRID závisí počet patchů na rozměrech vstupního obrázku a nastavit jej nelze.
- **Velikost patchů:** Velikost patche určuje, jak velkou část obrázku vidí *PatchCNN* najednou. Větší patche poskytují více prostorového kontextu (více tahů, mezery, strukturu slov), zatímco menší patche pokrývají užší oblast. Pixelové rozlišení se přitom nemění. Testovány byly čtvercové rozměry 15×15 , 25×25 , 40×40 a 48×48 pixelů.

Ostatní hyperparametry modelu (architektura Transformer encoderu, learning rate, weight decay, augmentace, velikost batche) byly fixovány na hodnotách odladěných předem na redukované trénovací sadě obsahující 10% autorů z původní trénovací sady.

5 Proces trénování

Jedná se o metric learning, kde se model učí mapovat vzorky stejného autora blízko sebe a vzorky odlišných autorů daleko od sebe. Jako ztrátová funkce byla použita ArcFace loss [1] se škálou 48 a marginem 0.5 rad, která maximalizuje úhlovou (cosinovou) mezitřídní separaci v L2 normalizovaném embeddingovém prostoru. Tento cíl je v souladu s použitím kosinové podobnosti pro porovnávání dotazovaného vzorku se vzorky v galerii.

Parametry modelu a ztrátové funkce byly optimalizovány pomocí oddělených optimalizérů AdamW. Model byl trénován s využitím automatické smíšené přesnosti (AMP), která kombinuje FP16 a FP32 výpočty a využívá gradient scaling pro stabilizaci tréninku. Ztrátová funkce ArcFace byla optimalizována v plné přesnosti (FP32) pro zajištění numerické stability. Důvodem bylo snížení výpočetní a paměťové náročnosti. Learning rate pro model byl 10^{-4} a pro ztrátovou funkci 5×10^{-5} . Weight decay byl nastaven na 10^{-4} . Dropout rate byl nastaven na hodnotu 0.1.

Modely byly trénovány po dobu 100 epoch. Checkpointing modelu probíhal při dosažení nového nejlepšího výkonu na validační sadě podle mAP metriky (viz sekce Evaluační protokol 6). Po 10 epochách bez zlepšení byl trénovací proces ukončen.

V každé epoše se model učí na všech autorech trénovací sady, přičemž pro každého autora je náhodně vybráno 32 vzorků z jeho dostupných dat, aby se vyrovnalo zastoupení autorů (někteří autoři mají tisíce vzorků). Použití vzorků se zaznamenává a v následujících epochách jsou již použité vzorky vybírány s nižší pravděpodobností. Velikosti batche a počet autorů v batchi byly nastaveny tak, aby každý batch obsahoval přesně čtyři vzorky na autora.

Augmentace dat

Augmentace jsou aplikovány pouze na vzorky autorů s méně než 200 vzorky v trénovací sadě, s cílem částečně vyrovnat jejich nerovnoměrné zastoupení.

Na každý obrázek je náhodně aplikována 1 až 4 fotometrické transformace vybrané z množiny přibližně 30 augmentací. Použité transformace zahrnují zejména úpravy kontrastu, jasu a saturace, Gaussovské rozostření, zaostření a aplikaci hranových filtrů.

6 Evaluační protokol

Evaluační vytvořeného modelu probíhala na úlohách identifikace v uzavřené a otevřené množině identit autorů pomocí gallery–probe protokolu. Testovací množina dat obsahovala 274 autorů, přičemž každému z nich bylo náhodně vybráno 50 vzorků za účelem zajištění rovnoměrného zastoupení autorů. Vzorky každého autora byly náhodně rozděleny na 25 vzorků uložených do galerie a zbývajících 25 vzorků použitých jako probe (dotazovací vzorky porovnáván se vzorky v galerii pro účely identifikace).

Embeddingy probe vzorku byly porovnávány pomocí kosinové podobnosti s embeddingy všech vzorků v galerii, čímž vzniklo jejich skórové ohodnocení. Čím vyšší bylo skóre, tím lepší byla shoda. Výstupem byl ranking vzorků podle dosaženého skóre. Pro získání skóre udávajícího míru příslušnosti

ke konkrétnímu autorovi v galerii byl vypočten aritmetický průměr 5 nejvyšších skóre vzorků daného autora. Výstupem byl následně ranking identit autorů podle výsledného skóre.

Evaluační na uzavřené množině identit autorů testovala, zda model správně přiřadil autora (a jeho referenční vzorky) k dotazovanému vzorku, přičemž každý dotazovaný vzorek náležel jednomu z autorů v galerii.

Hlavní metrikou byla Mean Average Precision (mAP), která hodnotí kvalitu rankingového seznamu vzorků v galerii vzhledem k dotazovanému vzorku, tedy retrieval výkon modelu. Další použitou metrikou byla Cumulative Match Characteristic (CMC), která vyjadřuje pravděpodobnost, že správná identita se nachází mezi prvními k pozicemi rankingu identit pro dotazovaný vzorek (Rank- k accuracy) pro všechny možné k .

Evaluační na otevřené množině identit autorů testovala, zda model dokáže nejen správně identifikovat vzorky známých autorů, ale také odmítnout vzorky neznámých autorů, kteří nejsou v galerii. Z galerie bylo odstraněno 50% náhodně vybraných autorů, a tudíž 50% probe vzorků nemělo odpovídat autorovi v galerii a bylo považováno za neznámé (impostory). Probe vzorky byly odmítány na základě porovnání nejvyššího dosaženého skóre autora v galerii s nastaveným prahem. Výstupem modelu byl buď nejpravděpodobnější autor, nebo odmítnutí (neznámá identita).

Hlavní metrikou byla křivka Open Set Classification Rate (OSCR), která udává hodnoty TPIR při různých hodnotách FPIR v intervalu 0 až 1. TPIR (True Positive Identification Rate) vyjadřuje pravděpodobnost, že dotazovaný vzorek bude přijat (jeho identita existuje v galerii) a zároveň mu bude přiřazena správná identita. Čím je TPIR vyšší, tím je systém lepší. FPIR (False Positive Identification Rate) udává pravděpodobnost, že neznámá identita bude chybně přijata. Čím je FPIR nižší, tím je systém lepší. Konkrétně nás zajímá TPIR při konkrétních operačních bodech FPIR (např. 10%) a také plocha pod OSCR křivkou (čím větší, tím lepší).

Evaluační na otevřené množině identit autorů byla opakována pětkrát (s náhodným výběrem neznámých identit) a naměřené hodnoty metrik byly následně zprůměrovány.


7 Výsledky experimentů

Tabulka 5 porovnává nejlepší dosažené výsledky jednotlivých strategií patchování na testovacím splitu spolu s baseline modelem postaveným na architektuře ResNet18. Označení Rank-1 je zkratkou pro Rank-1 accuracy, $\text{TPIR}_{0.1}$ znamená TPIR při 10% FPIR a AUC_{OSCR} označuje plochu pod OSCR křivkou.

Model	mAP	Rank-1	$\text{TPIR}_{0.1}$	AUC_{OSCR}
Baseline	0.790	0.953	0.916	0.942
RANDOM	0.774	0.955	0.893	0.929
SIFT	0.770	0.950	0.899	0.933
GRID	0.766	0.952	0.904	0.939

Tabulka 5: Srovnání nejlepších modelů.

Obrázek 3 zobrazuje OSCR křivky nejlepších modelů uvedených v tabulce 5. Graf charakterizuje chování systému v open-set režimu a ukazuje vztah mezi správnou identifikací známých autorů a chybou při přijímání neznámých



Obrázek 3: OSCR křivky nejlepších modelů.

Konfigurace	mAP	Rank-1	TPIR _{0.1}	AUC _{OSCR}
Baseline	0.810	0.962	0.916	0.942
SIFT				
$N=80, 48 \times 48$	0.751	0.947	0.880	0.926
$N=50, 48 \times 48$	0.770	0.950	0.899	0.933
$N=15, 48 \times 48$	0.696	0.924	0.809	0.896
GRID				
48×48	0.766	0.953	0.904	0.939
40×40	0.754	0.952	0.906	0.936
15×15	0.733	0.940	0.871	0.923
RANDOM				
$N=50, 48 \times 48$	0.774	0.955	0.893	0.929
$N=50, 25 \times 25$	0.756	0.949	0.854	0.914
$N=15, 48 \times 48$	0.752	0.948	0.834	0.911

Tabulka 6: Vybrané konfigurace jednotlivých patcherů.

autorů.

Tabulka 6 zachycuje vybrané konfigurace jednotlivých strategií patchování. Pro každý patcher je uvedena nejlepší konfigurace a dvě doplňující konfigurace ilustrující vliv počtu patchů a jejich rozměrů.

Diskuze výsledků

Porovnání strategií patchování. Všechny tři patch-based přístupy dosáhly srovnatelných výsledků: nejlepší mAP se pohybuje od 0.766 pro GRID po 0.774 pro RANDOM, přičemž rozdíl mezi nimi nepřesahuje 1 procentní bod. Baseline model ResNet18 (mAP = 0.810) je však stále přibližně o 4 procentní body lepší než nejlepší patch-based přístup.

Vliv počtu patchů. Pro metodu SIFT je počet patchů dominantním faktorem výkonu. Zvýšení z $N = 15$ na $N = 50$ přineslo nárůst mAP o 7.4 procentního bodu. Další zvýšení na $N = 80$ však výkon mírně snížilo na mAP = 0.751 (Tabulka 6). Příčinou je pravděpodobně nutnost snížit velikost dávky (batch size): každý vzorek s 80 patchi vyžaduje více paměti GPU, takže se do jedné dávky vejde méně vzorků. Menší dávka pak vede k méně stabilním odhadům gradientů při trénování. Dalším možným důvodem je vyšší redundance informací při příliš vysokém počtu patchů, která může ne-

gativně ovlivnit schopnost transformeru efektivně modelovat vztahy mezi relevantními reprezentacemi.

Zajímavé je srovnání SIFT a RANDOM při $N = 15$. SIFT dosahuje mAP = 0.696, zatímco RANDOM se stejným počtem patchů dosahuje 0.752. Sémantický výběr klíčových bodů SIFT tedy při malém počtu patchů nepomáhá. Klíčové body detekované metodou SIFT se typicky koncentrují do vizuálně výrazných oblastí (rohy tahů, křížení tahů), takže 15 SIFT patchů může hustě pokrýt stejnou část obrázku rukopisu a poskytnout nedostatečné pokrytí zbytku textu. Náhodné vzorkování přirozeně pokrývá plochu rukopisu rozmanitěji.

Vliv velikosti patchů. Metoda GRID vykazuje pozoruhodnou robustnost vůči velikosti patchů: i patche 15×15 px dosahují mAP = 0.733, tedy jen o 3.3 procentního bodu méně než nejlepší varianta 48×48 px (Tabulka 6). Důvodem je, že i když jsou patche menší, stále pokrývají celý obrázek a model vidí stejná data.

Nejlepší výkon na otevřené množině autorů při 10% FPIR dosáhl baseline model s TPIR 91,6% (Tabulka 5). Pro přísnější hodnoty FPIR však dominoval přístup GRID (Obrázek 3).

8 Závěr

V této práci byl prezentován systém pro identifikaci autora rukopisu v otevřené množině identit založený na zpracování lokálních patchů extrahovaných z obrazů ručně psaného textu. Navržené řešení kombinuje konvoluční enkodér patchů s transformer encoderem a attention poolingem pro vytvoření embeddingové reprezentace autora.

Součástí práce bylo vytvoření kompletní pipeline zahrnující přípravu datové sady, trénování modelu pomocí metrického učení a evaluaci v closed-set i open-set scénáři. Byly implementovány a porovnány tři strategie extrakce patchů: náhodné vzorkování, výběr podle pravidelné mřížky a výběr pomocí klíčových bodů SIFT. Experimenty byly provedeny na rozsáhlé datové sadě obsahující více než 5 milionů trénovacích vzorků rukopisu od více než 2 tisíc autorů.

Výsledky ukázaly, že patch-based přístupy jsou schopné dosahovat vysoké přesnosti identifikace autora i v open-set režimu. Současně se ukázalo, že jednoduchý baseline model založený na architektuře ResNet18 stále poskytuje nejlepší dosažené výsledky, což naznačuje, že lokální patchová reprezentace nemusí při použité architektuře plně zachytit globální charakteristiky rukopisu.

Poděkování

Výpočetní zdroje byly poskytnuty v rámci projektu e-INFRA CZ (ID:90254), který je podporován Ministerstvem školství, mládeže a tělovýchovy České republiky.

Dostupnost zdrojového kódu

Zdrojové kódy projektu jsou dostupné na: <https://github.com/dklajbl/knn-writer-identification>

Odkazy

- [1] Jiankang Deng et al. „ArcFace: Additive Angular Margin Loss for Deep Face Recognition“. In: *IEEE Trans. Pattern Anal. Mach. Intell.* 44.10 (2022), s. 5962–5979. DOI: [10.1109/TPAMI.2021.3087709](https://doi.org/10.1109/TPAMI.2021.3087709).
- [2] Kaiming He et al. „Deep Residual Learning for Image Recognition“. In: *2016 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2016, Las Vegas, NV, USA, June 27-30, 2016*. IEEE Computer Society, 2016, s. 770–778. DOI: [10.1109/CVPR.2016.90](https://doi.org/10.1109/CVPR.2016.90).
- [3] Michael Koepf, Florian Kleber a Robert Sablatnig. „Writer Identification and Writer Retrieval Using Vision Transformer for Forensic Documents“. In: *Document Analysis Systems - 15th IAPR International Workshop, DAS 2022, La Rochelle, France, May 22-25, 2022, Proceedings*. Ed. Seiichi Uchida, Elisa H. Barney Smith a Véronique Eglin. Lecture Notes in Computer Science. Springer, 2022, s. 352–366. DOI: [10.1007/978-3-031-06555-2_24](https://doi.org/10.1007/978-3-031-06555-2_24).
- [4] David G. Lowe. „Distinctive Image Features from Scale-Invariant Keypoints“. In: *Int. J. Comput. Vis.* 60.2 (2004), s. 91–110. DOI: [10.1023/B:VISI.0000029664.99615.94](https://doi.org/10.1023/B:VISI.0000029664.99615.94).
- [5] U. Marti a H. Bunke. „The IAM-database: an English sentence database for offline handwriting recognition“. In: *International Journal on Document Analysis and Recognition* 5 (2002), s. 39–46. DOI: [10.1007/s100320200071](https://doi.org/10.1007/s100320200071).
- [6] Filip Radenovic, Giorgos Tolias a Ondrej Chum. „Fine-Tuning CNN Image Retrieval with No Human Annotation“. In: *IEEE Trans. Pattern Anal. Mach. Intell.* 41.7 (2019), s. 1655–1668. DOI: [10.1109/TPAMI.2018.2846566](https://doi.org/10.1109/TPAMI.2018.2846566).
- [7] Adrià Molina Rodríguez et al. *The AnyScript Challenge: ICDAR 2026 Competition on Long-Term Handwriting Author Identification*. Online. Computer Vision Center, Universitat Autònoma de Barcelona, 2026. URL: <https://cvc-dag.github.io/anyscript/>.
- [8] Abdelillah Semma et al. „Writer Identification using Deep Learning with FAST Keypoints and Harris corner detector“. In: *Expert Syst. Appl.* 184 (2021), s. 115473. DOI: [10.1016/J.ESWA.2021.115473](https://doi.org/10.1016/J.ESWA.2021.115473).